

# 说明书

---

## 一种基于优先经验重放的深度强化学习频谱共享方法

### 技术领域

本发明涉及无线电通信领域，具体而言，涉及一种基于优先经验重放的深度强化学习频谱共享方法。

### 背景技术

随着移动数据通信的飞速发展，无线频谱资源需求正在急剧增长，在现有频谱授权机制下，频谱资源日益紧张且频谱利用率低。为了提高频谱利用率，现有研究能够在时间、频率以及空域上检测频谱资源占用状态，然后利用频谱资源多维复用技术、自适应编码调制技术、分集技术以及超宽带和扩频通信等传输技术，以降低频谱和带宽限制对无线通信发展的束缚。这些技术方案对无线电频谱的使用方面，虽然在一定程度上提高了系统传输容量和频谱利用率，但是传输容量和频谱资源不足问题依然突出。

无线电频谱的使用是一个动态变化的过程，要求频谱分配和管理模式具有相应的灵活性和适应性。认知无线网络是 5G 时代的核心网络结构，目前常采用认知无线电相关技术解决频谱资源管理模式不足导致的频谱利用率较低等问题。频谱共享作为认知无线电关键技术之一，是指在不改变现有的固定频谱分配框架下，认知终端通过调整系统工作参数，实现可用频谱资源高效利用的技术方案，已成为当今大数据时代解决频谱供需矛盾的热门话题。然而，随着无线宽带业务的迅猛发展以及海量频谱数据的增加，传统的频谱共享技术已经不再适用于当前 5G 大数据时代。因此，有必要提出新型的频谱共享技术，为认知无线电频谱资源的高效利用提供有力保障。

现有的无线业务产生海量的频谱数据，频谱数据的广度和深度不断扩增，带来了复杂的频谱大数据；而且，在基于频谱大数据进行频谱共享的过程中，由于存在频谱网络状态动态变化、环境条件未知等因素，导致需要先验样本进行训练的离线学习算法不再适用频谱共享决策过程。强化学习采用“学习—决策—执行”的方法，结合含有多层的神经网络并在神经网络每一层中对数据进行抽象化来学习并获取数据表达方式的深度学习，在频谱共享决策问题上有很大的优势。例如：根据信道的实时使用情况认知用户智能的调整发射端传输功率，选择最优频谱数据的网络，提高频谱的利用率。

申请号为“201810391479.4”的专利文件公开了“基于深度学习的多载波认知 NOMA 资源分配”，该方法提出一个优化 NOMA 系统频谱效率和能量效率的用户配对及资源分配策略，设计了基于消息传递的全连接神经网络并提出了最优的深度学习算法，实现了大规模 NOMA 用户公平且灵活地进行高质量、高速率、低功耗的数据传输。申请号为“201710717867.2”的

专利文件公开了“一种基于契约理论的协作频谱共享动态激励机制设计方法”，该方法通过将无线协作频谱共享网络映射成劳动力市场，将基于市场驱动的契约模型引入到协作频谱共享机制中，建立了主用户模型和次级用户模型，实现了对无线频谱资源的高效利用。上述频谱共享方法，虽然从深度学习和契约理论等方面实现频谱共享，提高了频谱利用率，但是未考虑在当前频谱大数据的无线业务下，频谱网络状态动态变化、环境条件未知等因素对频谱共享灵活性和适应性的要求。

### 发明内容

本发明针对基于频谱大数据进行频谱共享时存在的频谱网络状态动态变化、环境条件未知等因素，提出一种具优先经验重放的深度 Q 网络方法，实现认知用户对主用户频谱的共享。该方法与传统的深度强化学习频谱共享方法相比，在“学习—决策—执行”模式的训练中使用基于优先级的采样方式替代均匀采样，区分不同转移样本之间的重要性差异，提高了有价值样本的采样概率，避免有价值的样本被覆盖或者重复利用，从而加快频谱共享最优策略学习。实验表明：本发明提出的基于优先经验重放的深度强化学习频谱共享方法具有更高的成功率和更快的收敛性。

本发明的目的在于提供一种基于优先经验重放的深度强化学习频谱共享方法，满足在当前频谱大数据无线业务下，频谱网络状态动态变化、环境条件未知等因素对频谱共享灵活性和适应性的要求。

为解决上述技术问题，本发明采用如下的技术方案：一种基于优先经验重放的深度强化学习频谱共享方法，包括以下步骤：

S1，构建频谱共享模型；

S2，在 S1 频谱共享模型下，将频谱共享问题建模为深度强化学习中智能体与环境交互的马尔科夫决策过程（MDP），训练基于样本优先经验重放的深度强化学习模型，获得认知用户功率传输的学习价值信息；

S3，根据 S2 所获取的认知用户功率传输学习价值信息做出频谱大数据下频谱共享控制决策，其中，所述控制决策实现了认知用户通过调节自身传输功率在不影响主用户通信质量下共享主用户的频谱，达到可用频谱资源的高效利用。

优选的，步骤 S1 中，构建频谱共享模型。

进一步优选的，步骤 S1 包括以下步骤：

在该模型中，频谱共享模型包括主用户和认知用户，它们以非协作的方式工作。主用户根据自身的功率控制策略更新发射功率，认知用户采用基于优先经验重放的深度强化学习机

制更新发射功率来共享主用户的频谱。

信干噪比是度量主用户和认知用户的服务质量 QoS；第  $i$  个接收机的 SINR <sub>$i$</sub>  为：

$$\text{SINR}_i = \frac{|h_{ii}|^2 P_i}{\sum_{j \neq i} |h_{ji}|^2 P_j + N_i}, \text{ 其中, } h_{ij} \text{ 表示发射端 } i \text{ 到接收端 } j \text{ 的信道增益, } p_i \text{ 是第 } i \text{ 个发射端的传}$$

输功率,  $N_i$  表示第  $i$  个接收端噪声功率。

假设主用户接收端和认知用户接收端成功接收传输数据必须满足一个最小的 SINR，即：

$$\text{SINR}_i \geq \mu_i, i=1,2. \text{ 主用户功率控制策略算法为: } P_{pu}(t+1) = \mathfrak{I}\left(\frac{\mu_1 P_{pu}(t)}{\text{SINR}_1(t)}\right), \text{ 其中, } P_{pu}(t) \text{ 表示在第 } t \text{ 个}$$

时间帧主用户的传输功率,  $\text{SINR}_1(t)$  表示在第  $t$  个时间帧主用户接收端测得的信干噪比,  $\mathfrak{I}(\cdot)$  表示一个离散化操作, 目的是将一组连续的值映射到一组离散的值上, 即  $p_{pu}(t) = \{p_{pu}^1, \dots, p_{pu}^L\}$ , 其

$$\text{中 } p_{pu}^1 \leq \dots \leq p_{pu}^L, \text{ 且 } \mathfrak{I}(x) = \begin{cases} p_{pu}^m & x > P_{pu}^m, m \in (1, L) \\ p_{pu}^L & x > P_{pu}^L \end{cases}.$$

优选的, 步骤 S2 中, 在 S1 频谱共享模型下, 将频谱共享问题建模为深度强化学习中智能体与环境交互的马尔科夫决策过程, 训练基于样本优先经验重放的深度强化学习模型, 获得认知用户功率传输的学习价值信息。

进一步优选的, 步骤 S2 包括以下步骤:

S21, 经验池初始化容量为  $D$ , 神经网络初始化; 设定经验池为一个满二叉树, 叶子节点可储存  $D$  个状态动作对; 初始化 Q 网络的权重参数为  $\theta$ , 目标网络  $\hat{Q}$  的权重参数为  $\theta_- = \theta$ ;

S22, 将频谱共享问题建模为深度强化学习中智能体与环境交互的马尔科夫决策过程, 建立状态空间  $S(t)$ , 动作空间  $A$  定义以及即时奖赏  $r_{ss'}^a(t)$  计算模型;

S23, 积累具有样本优先级的经验池, 其特征在于, 具体步骤如下:

1) 初始化状态空间  $S(1)$ 。根据当前输入状态  $S(1)$ , 通过 Q 网络得到全部动作, 利用  $\varepsilon$  贪心算法选取动作, 具体是以  $\varepsilon$  的概率从动作空间  $A$  选择一个动作  $a(t)$ , 否则以  $1-\varepsilon$  的概率选取最大 Q 值的动作  $a_t = \max_{a_t} Q(s_t, a; \theta)$ , 其中  $t$  表示时间;

2) 根据步骤 S1 中主用户的功率更新策略更新主用户的传输功率, 执行动作  $a(t)$ , 得到即时奖励  $r_{ss'}^a(t)$  和  $t+1$  时刻的状态  $S(t+1)$ ;

3) 将  $t+1$  时刻的状态  $S(t+1)$  作为当前输入状态, 重复步骤 1) 和 2), 将计算得到的状态动作对  $e(t) \triangleq \{S(t), a(t), r(t), S(t+1)\}$  和最大优先级  $d_t = \max_{i < t} d_i$  存到满二叉树构成的经验池中, 满二叉树中只有叶子节点储存状态动作对;

4) 重复步骤 3)直到经验池的  $D$  空间被储存满，经验池的满二叉树储存满后每执行一次步骤 3)便跳转执行一次步骤 S24；

S24，训练频谱共享模型下深度强化学习神经网络，其特征在于，具体步骤如下：

1) 从满二叉树中采样小批量  $O$  的  $e(t)$ ，每个样本被采样的概率基于  $j \sim D(j) = d_j^a / \sum_i d_i^a$ ，采样样本储存在一个  $(m,n)$  的二维矩阵，其中， $m$  为样本容量大小， $n$  为每个样本储存的信息数量，满足  $n = 2*s + a + 1$ ， $s$  为状态的维度， $a$  为动作的维度，1 为存储奖励信息的预留空间；

2) 对步骤 1)中的小批量样本  $O$  计算每个  $e(t)$  采样样本  $j \sim D(j) = d_j^a / \sum_i d_i^a$ ；

3) 对步骤 1)中的小批量样本  $O$  计算每个  $e(t)$  样本重要性采样权重  $\omega$ ，采样权重主要是为了纠正网络训练过拟合问题，即： $w_j = (N \cdot D(j))^{-\beta} / \max_i w_i$ ，其中  $\beta$  表示纠正程度；

4) 计算 1)所有样本的时序误差  $\delta_j = R_j + \gamma \hat{Q}(S'_j, \arg \max_a Q(S'_j, a; \theta_-) - Q(S_j, A_j; \theta_-)) - Q(S_j, A_j; \theta_-)$ ，并更新满二叉树中所有节点的优先级  $d_j \leftarrow |\delta_j|$ ；

5) 使用均方差损失函数  $L(\theta) = \frac{1}{O} \sum_{j=1}^m w_j (y_j - Q(S_j, A_j, \theta))^2$ ，通过神经网络的 Adam 梯度反向传播来更新  $Q$  网络的所有参数  $\theta$ ；

6) 如果  $t$  是更新步长  $C$  的整数倍，更新目标网络  $\hat{Q}$  参数  $\theta_- = \theta$ ；

7) 如果  $S(t+1)$  是终止状态，当前训练完成，否则转到步骤 S23。

通过本发明的上述方法，训练基于认知用户样本优先经验重放的深度强化学习模型，实现频谱大数据下频谱共享过程。首先，初始化认知用户的传输功率，得到状态  $S(1)$ ；然后选择动作  $a_t = \max_{a_t} Q(s_t, a; \theta^*)$  得到  $S(t+1)$ ，即在  $t+1$  时刻认知用户通过优先经验重放的深度强化学习模型智能更新传输功率，在不影响主用户的通信质量下共享主用户的频谱，其中  $\theta^*$  为已训练神经网络的权重参数。

所述基于优先经验重放的深度强化学习频谱共享方法中，控制动作直接取决于系统的状态。将选择传感器节点的接收功率作为状态空间，即： $S(t) = [p_1^s(t), \dots, p_N^s(t)]^T$ ，其中  $N$  为频谱共享模型中传感器节点的数量。传感器节点是为了辅助认知用户学习有效的功率控制策略而在频谱共享模型中设置的，它可以测量在无线电环境中不同位置的接收信号强度，该信号强度由主用户和认知用户的传输功率控制，且只有认知用户可以访问。 $P_n^s(t)$  表示  $t$  时刻传感器节点  $n$  的接收功率，满足  $P_n^s(t) = P_{pu}(t)g_{pn} + P_{su}(t)g_{sn} + w_n(t)$ ，其中  $P_{pu}(t)$  和  $P_{su}(t)$  分别表示主用户和认知用户的传输功率， $w_n(t)$  表示具有方差的零均值高斯随机变量， $g_{pn}$  和  $(g_{sn})$  表示主用户(知用户)

端与传感器节点  $n$  之间传输的路径损耗, 满足  $g_{pn} = (\lambda/4\pi d_{pn})^2$ ,  $g_{sn} = (\lambda/4\pi d_{sn})^2$ , 其中  $\lambda$  表示信号波长,  $d_{pn}(d_{sn})$  表示主用户(认知用户)发射端与传感器节点  $n$  的距离。

所述基于优先经验重放的深度强化学习频谱共享方法, 如何在干扰主用户通信下选择认知用户的传输功率满足主用户和认知用户各自的通信需求是实现频谱共享问题的核心。因此, 选取认知用户的传输功率作为控制动作, 即  $A(t) = P_{su}(t)$ , 其中  $P_{su}(t) = \{P_{su}^1, \dots, P_{su}^L\}$ ,  $P_{su}^1 \leq \dots \leq P_{su}^L$ 。认知用户通过在每个时刻  $t$  收集的传感器节点接收信号强度智能学习并调节自身传输功率, 使得主用户和认知用户能够在满足 QoS 需求下成功的传输数据。

所述基于优先经验重放的深度强化学习频谱共享方法, 认知用户总是试图通过在每个时间步骤  $t$  采取最佳行动(传输功率)最大化可以获得的奖励。选取常数  $C$  作为即时奖励, 假设当主用户接收端和认知用户接收端成功接受数据的同时都能够满足一个最小信干噪比要求可获得的奖励  $C$ , 即时奖励函数为:  $r_{ss'}^a(t) = \begin{cases} C & \text{SINR}_1(t+1) \geq \mu_1 \cap \text{SINR}_2(t+1) \geq \mu_2 \\ 0 & \text{otherwise} \end{cases}$ , 其中  $r_{ss'}^a(t)$  指  $t$  时刻在状态  $s$  下采取动作  $a$  到状态  $s'$  的即时奖励。

与现有技术相比, 本发明提供了一种频谱大数据下基于优先经验重放的深度强化学习频谱共享方法, 在频谱网络状态动态变化、环境条件未知等因素下实现可用频谱资源的高效利用。本发明将频谱共享问题建模为强化学习中智能体与环境交互的 MDP。利用 MDP 中的状态、行为和奖励描述频谱共享问题, 并将强化学习和深度神经网络结合智能提取认知用户传输功率的学习价值特征, 实现认知用户对自身传输功率智能更新, 以便共享主用户频谱。本发明与传统深度强化学习频谱共享方法相比, 每  $t$  时刻经验回放机制在线地储存和使用智能体与环境交互得到历史样本时, 经验回放机制使用优先级采样方式替代等概率均匀采样方式, 对深度强化学习频谱共享模型进行训练。该经验回放机制不仅能够消除转移样本之间的时间相关性, 而且能够区分出不同转移样本之间的重要性差异, 避免了由于样本池  $D$  的存储量有限, 某些有价值样本还未被充分利用就已经被舍弃等问题, 提高了有价值样本的采样概率, 从而加快了认知用户功率传输最优策略的学习。

发明人经过大量研究表明: 本发明提供的一种基于优先经验重放的深度强化学习频谱共享方法, 与传统的深度强化学习频谱共享方法相比, 具有更高的成功率和更快的收敛性, 能成功地在干扰主用户通信质量下认知用户智能的更新自身传输功率共享主用户的频谱, 实现了主用户和认知用户在满足信道通信质量情况下传输各自的数据, 提高了通信需求。

附图说明

通过参考附图会更加清楚的理解本发明的特征和优点，附图是示意性的而不应对本发明进行任何限制，在附图中：

图 1 是本发明实施例的方法流程示意框图；

图 2 是本发明实施例中使用的认知无线电的频谱共享模型图；

图 3 是本发明实施例的评价网络结构图；

图 4 是本发明实例中的损失函数图；

图 5 是本发明实例中的成功率图。

## 具体实施方式

为了能够更清楚地理解本发明的上述目的、特征和优点，下面结合附图和具体实施方式对本发明进行进一步的详细描述。需要说明的是，在不冲突的情况下，本申请的实施例及实施例中的特征可以相互组合。

在下面的描述中阐述了很多具体细节以便于充分理解本发明，但是，本发明还可以采用其他不同于在此描述的方式来实施，因此，本发明的保护范围并不受下面公开的具体实施例的限制。

参看图1-图6，本发明实施例提供了一种基于优先经验重放的深度强化学习频谱共享方法，所述方法的步骤如下：

S1，构建频谱共享模型(如图 2 所示)，该模型包括主用户和认知用户。在该模型中，主用户和认知用户以非协作的方式工作，主用户根据自身的功率控制策略更新发射功率，而功率控制策略取决于环境状态，因此认知用户在当前时刻的发射功率选择将影响主用户的在下一时刻发射功率的更新。认知用户采用基于优先经验重放的深度强化学习机制更新发射功率来共享主用户的频谱，为了辅助认知用户学习有效的功率控制策略，在无线环境频谱共享模型中设置传感器节点，它可以测量在无线电环境中不同位置的接收信号强度，该信号强度由主用户和认知用户的传输功率控制，且只有认知用户可以访问接收信号强度。

S2，在 S1 频谱共享模型下，将频谱共享问题建模为深度强化学习中智能体与环境交互的马尔科夫决策过程，训练基于样本优先经验重放的深度强化学习模型，获得认知用户功率传输的学习价值信息。具体包括以下步骤：

S21，经验池初始化容量为  $D$ ，神经网络初始化；设定经验池为一个满二叉树，叶子节点可储存  $D$  个状态动作对；初始化 Q 网络的权重参数为  $\theta$ ，目标网络  $\hat{Q}$  的权重参数为  $\theta_- = \theta$ ；

S22，将频谱共享问题建模为深度强化学习中智能体与环境交互的马尔科夫决策过程，建立状态空间  $S(t)$ ，动作空间  $A$  定义以及即时奖赏  $r_{ss'}^a(t)$  计算模型；

S23, 积累具有样本优先级的经验池, 其特征在于, 具体步骤如下:

- 1) 初始化状态空间  $S(1)$ 。根据当前输入状态  $S(1)$ , 通过Q网络得到全部动作, 利用  $\varepsilon$  贪心算法选取动作, 具体是以  $\varepsilon$  的概率从动作空间  $A$  选择一个动作  $a(t)$ , 否则以  $1-\varepsilon$  的概率选取最大Q值的动作  $a_t = \max_{a_i} Q(s_t, a; \theta)$ , 其中  $t$  表示时间;
- 2) 根据步骤 S1 中主用户的功率更新策略更新主用户的传输功率, 在执行动作  $a(t)$  后, 得到即时奖励  $r_{ss'}^a(t)$  和  $t+1$  时刻的状态  $S(t+1)$ ;
- 3) 将  $t+1$  时刻的状态  $S(t+1)$  作为当前输入状态, 重复步骤 1)和 2), 将计算得到的状态动作对  $e(t) \triangleq \{S(t), a(t), r(t), S(t+1)\}$  和最大优先级  $d_t = \max_{i < t} d_i$  存到满二叉树构成的经验池中, 满二叉树中只有叶子节点储存状态动作对;
- 4) 重复步骤 3)直到经验池的  $D$  空间被储存满, 经验池的满二叉树储存满后每执行一次步骤 3)便跳转执行一次步骤 S24;

S24, 训练频谱共享模型下深度强化学习神经网络, 其特征在于, 具体步骤如下:

- 1) 从满二叉树中采样小批量  $O$  的  $e(t)$ , 每个样本被采样的概率基于  $j \sim D(j) = d_j^a / \sum_i d_i^a$ , 采样样本储存在一个  $(m, n)$  的二维矩阵, 其中,  $m$  为样本容量大小,  $n$  为每个样本储存的信息数量, 满足  $n = 2 * s + a + 1$ ,  $s$  为状态的维度,  $a$  为动作的维度, 1 为存储奖励信息的预留空间;
- 2) 对步骤 1)中的小批量样本  $O$  计算每个  $e(t)$  采样样本  $j \sim D(j) = d_j^a / \sum_i d_i^a$ ;
- 3) 对步骤 1)中的小批量样本  $O$  计算每个  $e(t)$  样本重要性采样权重  $\omega$ , 采样权重主要是为了纠正网络训练过拟合问题, 即:  $w_j = (N \cdot D(j))^{-\beta} / \max_i w_i$ , 其中  $\beta$  表示纠正程度;
- 4) 计算 1)所有样本的时序误差  $\delta_j = R_j + \gamma \hat{Q}(S'_j, \arg \max_a Q(S'_j, a; \theta); \theta_-) - Q(S_j, A_j; \theta)$ , 并更新满二叉树中所有节点的优先级  $d_j \leftarrow |\delta_j|$ ;
- 5) 使用均方差损失函数  $L(\theta) = \frac{1}{O} \sum_{j=1}^m w_j (y_j - Q(S_j, A_j, \theta))^2$ , 通过神经网络的 Adam 梯度反向传播来更新  $Q$  网络的所有参数  $\theta$ ;
- 6) 如果  $t$  是更新步长  $C$  的整数倍, 更新目标网络  $\hat{Q}$  参数  $\theta_- = \theta$ ;
- 7) 如果  $S(t+1)$  是终止状态, 当前训练完成, 否则转到步骤 S23。

S3, 根据 S2 所获取的认知用户功率传输学习价值信息判断频谱大数据下频谱共享控制决策, 其中, 所述控制决策实现了认知用户通过调节自身传输功率在不影响主用户通信质量下共享主用户的频谱, 具体包括: 通过 S2 方法, 训练好基于优先经验重放的深度强化学习模型可实现认知无线电中频谱共享, 首先初始化认知用户的传输功率, 得到状态  $S(1)$ ; 然后选择动作

$a_t = \max_{a_t} Q(s_t, a; \theta^*)$ ，其中  $\theta^*$  为训练好的神经网络的权重参数，得到  $S(t+1)$ ，即在下一时刻  $t+1$  的认知用户在不影响主用户的通信质量下共享主用户的频谱，实现可用频谱的高效利用。

为了验证本发明的效果，发明人还进行了以下仿真实验：

仿真条件：频谱共享模型中，设置从主用户/认知用户到主用户/认知用户的信道增益  $h_{ij}=1, \forall i, j$ ；设置传感器节点数为 10；设置主用户接收端和认知用户接收端成功传输数据满足的一个最小 SINR 分别为  $\mu_1=1.2, \mu_2=0.7$ ；附图 5 中的损失函数为  $L(\theta) = \frac{1}{o} \sum_{j=1}^m w_j (y_j - Q(S_j, A_j, \theta))^2$ ，其中  $y_j = R_j + \gamma_j Q'_{target}(S'_j, \arg \max_a Q(S'_j, a, \theta), \theta^-)$ 。

图 4 是损失函数随着迭代次数变化曲线图，仿真环境设置：迭代次数 K 为 3000，经验池容量 D 为 400，小批量抽样数 Q 为 128，在训练的 k 次迭代之后，认知用户可以使用训练过的网络智能的调节自身传输功率来共享主用户的频谱。从图 5 可以看出，随着迭代次数的不断增加，损失函数逐渐递减，在迭代 450 次时，损失函数逐渐收敛，损失函数是预测该算法模型好坏的衡量标准，这表明本发明提出的一种基于优先经验重放的深度强化学习频谱共享方法，有较好的收敛性和稳健性。图 5 是成功率随着迭代次数变化曲线图，是该算法性能评估指标，成功率为成功试验的次数与独立运行的总次数之比，本发明设置在 20 个时间框架内移动到目标状态（主用户接收端和认知用户接收端成功接受通信数据的同时都能够满足一个最小信干噪比要求），则认为试验成功。从图 5 中可以看出，随着迭代次数的不断增加，成功率逐渐递增，在迭代 450 次时，成功率达到百分之九十多，与损失函数的收敛一致。这表明本发明提出的一种基于优先经验重放的深度强化学习频谱共享方法，有较高的成功率。且本发明该方法能成功的使在不干扰主用户通信下选择认知用户的传输功率，使主用户和认知用户在满足信道通信质量的情况下传输各自的数据，提高了通信需求。

为了验证本发明的效果，发明人进行了大量的仿真实验，均证明本发明方法的效果更优于现有技术（一种基于优先级重放的深度强化学习频谱共享，与传统的深度强化学习频谱共享相比，它使得认知用户能够在与主用户进行一系列交互后智能地更新传输功率以共享主用户的频谱，该算法具有较高的成功率和较快的收敛性），以上实验例仅仅是从众多的仿真实验中随意选出的一个，用于证明本发明的技术效果，其并不作为对本发明技术方案的限定。

在本发明中，术语“第一”、“第二”、“第三”仅用于描述目的，而不能理解为指示或暗示相对重要性。术语“多个”指两个或两个以上，除非另有明确的限定。



## 说 明 书

---

以上所述仅为本发明的优选实施例而已，并不用于限制本发明，对于本领域的技术人员来说，本发明可以有各种更改和变化。凡在本发明的精神和原则之内，所作的任何修改、等同替换、改进等，均应包含在本发明的保护范围之内。